Task02 数据读取与数据扩增

一、图像读取

比较常见的有Pillow和OpenCV。

1、Pillow

Pillow是Python图像处理函式库(PIL）的一个分支。Pillow提供了常见的图像读取和处理的操作，而且可以与ipython notebook无缝集成，是应用比较广泛的库。

效果	代码

	from PIL import Image
	# 导入Pillow库
	
	# 读取图片
	im =Image.open(cat.jpg')

	from PIL import Image, ImageFilter
	im = Image.open('cat.jpg')
	# 应用模糊滤镜:
	im2 = im.filter(ImageFilter.BLUR)
	im2.save('blur.jpg', 'jpeg')

	from PIL import Image
	# 打开一个jpg图像文件，注意是当前路径:
	im = Image.open('cat.jpg')
	im.thumbnail((w//2, h//2))
	im.save('thumbnail.jpg', 'jpeg')

Pillow的官方文档：https://pillow.readthedocs.io/en/stable/

2、OpenCV

OpenCV是一个跨平台的计算机视觉库，最早由Intel开源得来。OpenCV发展的非常早，拥有众多的计算机视觉、数字图像处理和机器视觉等功能。

效果	代码

	import cv2
	# 导入Opencv库
	img = cv2.imread('cat.jpg')
	# Opencv默认颜色通道顺序是BRG，转换一下
	img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

	import cv2
	# 导入Opencv库
	img = cv2.imread('cat.jpg')
	img = cv2.cvtColor(img,
	cv2.COLOR_BGR2GRAY)
	# 转换为灰度图

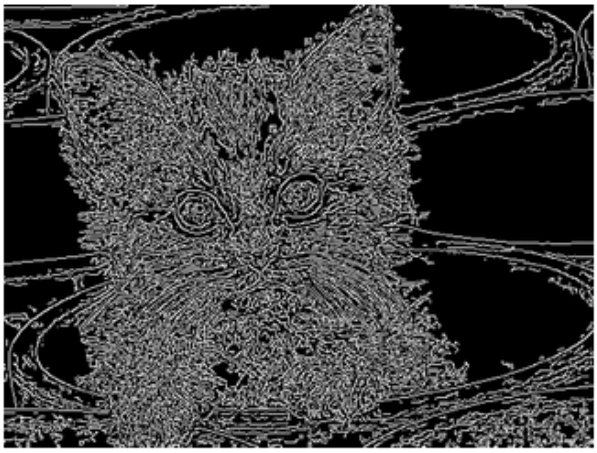	import cv2
	# 导入Opencv库
	img = cv2.imread('cat.jpg')
	img =cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
	# 转换为灰度图
	# Canny边缘检测
	edges = cv2.Canny(img, 30, 70)
	cv2.imwrite('canny.jpg', edges)

OpenCV包含了众多的图像处理的功能，OpenCV包含了你能想得到的只要与图像相关的操作。此外OpenCV还内置了很多的图像特征处理算法，如关键点检测、边缘检测和直线检测等。

OpenCV官网：https://opencv.org/

OpenCV Github：https://github.com/opencv/opencv

OpenCV 扩展算法库：https://github.com/opencv/opencv_contrib

二、数据扩增

数据扩增可以增加训练集的样本，同时也可以有效缓解模型过拟合的情况，也可以给模型带来的更强的泛化能力。

在深度学习模型的训练过程中，数据扩增是必不可少的环节。现有深度学习的参数非常多，一般的模型可训练的参数量基本上都是万到百万级别，而训练集样本的数量很难有这么多。
其次数据扩增可以扩展样本空间，假设现在的分类模型需要对汽车进行分类，左边的是汽车A，右边为汽车B。如果不使用任何数据扩增方法，深度学习模型会从汽车车头的角度来进行判别，而不是汽车具体的区别。

常见数据扩增方法：

以torchvision为例，常见的数据扩增方法包括：

- transforms.CenterCrop　对图片中心进行裁剪
- transforms.ColorJitter　对图像颜色的对比度、饱和度和零度进行变换
- transforms.FiveCrop　对图像四个角和中心进行裁剪得到五分图像
- transforms.Grayscale　对图像进行灰度变换
- transforms.Pad　使用固定值进行像素填充
- transforms.RandomAffine　随机仿射变换
- transforms.RandomCrop　随机区域裁剪
- transforms.RandomHorizontalFlip　随机水平翻转
- transforms.RandomRotation　随机旋转
- transforms.RandomVerticalFlip　随机垂直翻转

在本次赛题中，赛题任务是需要对图像中的字符进行识别，因此对于字符图片并不能进行翻转操作。比如字符6经过水平翻转就变成了字符9，会改变字符原本的含义。

torchvision：https://github.com/pytorch/vision
pytorch官方提供的数据扩增库，提供了基本的数据数据扩增方法，可以无缝与torch进行集成；但数据扩增方法种类较少，且速度中等。

三、数据读取

在Pytorch中数据是通过Dataset进行封装，并通过DataLoder进行并行读取。所以我们只需要重载一下数据读取的逻辑就可以完成数据的读取。

```
import os, sys, glob, shutil, json
import cv2

from PIL import Image
import numpy as np

import torch
from torch.utils.data.dataset import Dataset
import torchvision.transforms as transforms

class SVHNDataset(Dataset):
```

```
    def __init__(self, img_path, img_label, transform=None):
        self.img_path = img_path
        self.img_label = img_label
        if transform is not None:
            self.transform = transform
        else:
            self.transform = None

    def __getitem__(self, index):
        img = Image.open(self.img_path[index]).convert('RGB')

        if self.transform is not None:
            img = self.transform(img)

        # 原始SVHN中类别10为数字0
        lbl = np.array(self.img_label[index], dtype=np.int)
        lbl = list(lbl)  + (5 - len(lbl)) * [10]

        return img, torch.from_numpy(np.array(lbl[:5]))

    def __len__(self):
        return len(self.img_path)

train_path = glob.glob('../input/train/*.png')
train_path.sort()
train_json = json.load(open('../input/train.json'))
train_label = [train_json[x]['label'] for x in train_json]

data = SVHNDataset(train_path, train_label,
          transforms.Compose([
              # 缩放到固定尺寸
              transforms.Resize((64, 128)),

              # 随机颜色变换
              transforms.ColorJitter(0.2, 0.2, 0.2),

              # 加入随机旋转
              transforms.RandomRotation(5),

              # 将图片转换为pytorch 的tesntor
              # transforms.ToTensor(),

              # 对图像像素进行归一化
              # transforms.Normalize([0.485,0.456,0.406],
[0.229,0.224,0.225])
          ]))
```

通过上述代码，可以将赛题的图像数据和对应标签进行读取，在读取过程中的进行数据扩增。

接下来我们将在定义好的Dataset基础上构建DataLoder，你可以会问有了Dataset为什么还要有DataLoder？其实这两个是两个不同的概念，是为了实现不同的功能。

- Dataset：对数据集的封装，提供索引方式的对数据样本进行读取
- DataLoder：对Dataset进行封装，提供批量读取的迭代读取

加入DataLoder后，数据读取代码改为如下：

```
import os, sys, glob, shutil, json
```

```
import cv2

from PIL import Image
import numpy as np

import torch
from torch.utils.data.dataset import Dataset
import torchvision.transforms as transforms

class SVHNDataset(Dataset):
    def __init__(self, img_path, img_label, transform=None):
        self.img_path = img_path
        self.img_label = img_label
        if transform is not None:
            self.transform = transform
        else:
            self.transform = None

    def __getitem__(self, index):
        img = Image.open(self.img_path[index]).convert('RGB')

        if self.transform is not None:
            img = self.transform(img)

        # 原始SVHN中类别10为数字0
        lbl = np.array(self.img_label[index], dtype=np.int)
        lbl = list(lbl)  + (5 - len(lbl)) * [10]

        return img, torch.from_numpy(np.array(lbl[:5]))

    def __len__(self):
        return len(self.img_path)

train_path = glob.glob('../input/train/*.png')
train_path.sort()
train_json = json.load(open('../input/train.json'))
train_label = [train_json[x]['label'] for x in train_json]

train_loader = torch.utils.data.DataLoader(
        SVHNDataset(train_path, train_label,
                    transforms.Compose([
                        transforms.Resize((64, 128)),
                        transforms.ColorJitter(0.3, 0.3, 0.2),
                        transforms.RandomRotation(5),
                        transforms.ToTensor(),
                        transforms.Normalize([0.485, 0.456, 0.406], [0.229, 0.224, 0.225])
            ])),
    batch_size=10, # 每批样本个数
    shuffle=False, # 是否打乱顺序
    num_workers=10, # 读取的线程个数
)

for data in train_loader:
    break
```